Aprendizaje No Supervisado



Universidad Internacional de Valencia

T1.2 – Distancia y Evaluacion

José María Escalante Fernández
Curso 2026-2027 (Ed Abril - Grupo B)

Máster Univ. en
Inteligencia Artificial

De:
Planeta Formación y Universidades

¿Cómo funciona un modelo de Aprendizaje No Supervisado?

A diferencia del aprendizaje supervisado, donde el modelo aprende a relacionar unas entradas con una salida conocida, en el Aprendizaje No Supervisado se parte únicamente de los datos:

N características

M instancias o muestras

	X_1	X_2	X3	…	X_n
I_1	X_{11}	X_{12}	X_{13}	…	X_{1n}
I_2	X_{21}	X_{22}	X_{23}	…	X_{2n}
I_3	X_{31}	X_{32}	X_{23}	…	X_{3n}
…	…	…	…	…	…
I_M	X_{M1}	X_{M2}	X_{M3}	…	X_{Mn}

No son etiquetas, solo identificas la instancia

¿Cómo funciona un modelo de Aprendizaje No Supervisado?

Universidad Internacional de Valencia

Los modelos parten directamente de los datos. Entonces surge la siguiente cuestión:

Si no damos un tipo de feedback al sistema para que aprenda
¿Cómo funciona el algoritmo? ¿Cómo aprende?

Buscando similitudes o disimilitudes en los datos, según convenga al modelo usado, para buscar relaciones entre datos y estructuras.

¿Cómo buscamos esas similitudes?

DISTANCIA: Similitud y Disimilitud

Universidad Internacional de Valencia

N características

M instancias o muestras

	X_1	X_2	X3	…	X_n
I_1	X_{11}	X_{12}	X_{13}	…	X_{1n}
I_2	X_{21}	X_{22}	X_{23}	…	X_{2n}
I_3	X_{31}	X_{32}	X_{23}	…	X_{3n}
…	…	…	…	…	…
I_M	X_{M1}	X_{M2}	X_{M3}	…	X_{Mn}

Vector representación de la muestra o instancia I_3

No son etiquetas, solo identificas la instancia

DISTANCIA: Similitud y Disimilitud

SIMILITUD: mide cuánto se parecen dos muestras → $S(I_i, I_j)$.

DISIMILITUD: mide cuánto se diferencian dos muestras → $D(I_i, I_j)$.

$S(I_i, I_j) + D(I_i, I_j) = 1$ $\quad$ $S(I_i, I_j) = 1 - D(I_i, I_j) = 1$

Alta similitud implica baja disimilitud y viceversa.

Los conceptos de SIMILITUD y DISIMILITUD están estrechamente relacionados con el concepto de DISTANCIA [$d(I_i, I_j)$].

Si cada instancia o muestra viene caracterizada por un vector, se puede definir una distancia, una norma, que indique como de cerca o lejos estén dos muestras, indicando el grado similitud o disimilitud.

DISTANCIA: Similitud y Disimilitud

Aquí debemos ver el concepto de distancia en su forma mas amplia, ya que hay muchos tipos de distancias en matemáticas. Bajo una serie de condiciones se puede considerar que:

$$D(I_i, I_j) \sim d(I_i, I_j)$$

¿Cuáles son estas condiciones?

- **No negativa**: $d(I_i, I_j) \geq 0, \forall I_i, I_j$
- **Simétrico**: $d(I_i, I_j) = d(I_j, I_i)\ 0, \forall I_i, I_j$
- **Distancia de los indiscernibles**: $d(I_i, I_j) = 0$ si y solo si $I_i = I_j, \forall I_i, I_j$
- **Desigualdad triangular**: $d(I_n, I_m) \leq d(I_n, I_k) + d(I_k, I_m), \forall I_n, I_m, I_k$

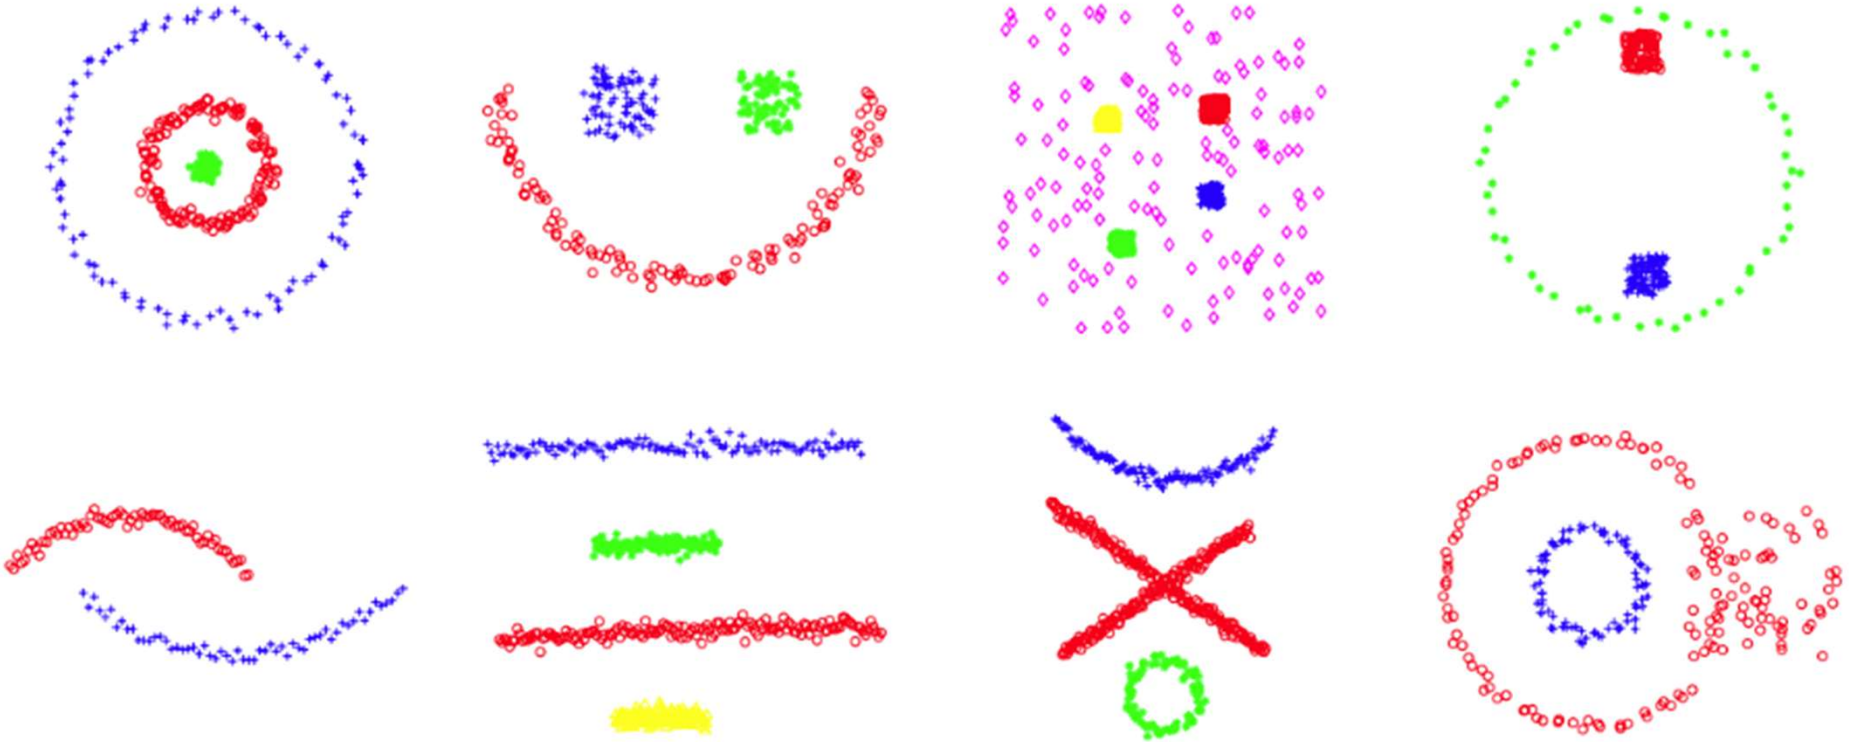
DISTANCIA: Similitud y Disimilitud



Existen diferentes tipos de distancias:

- Euclidea
- Manhattan
- Chebyshev
- Hamming
- Jaccard
- Coseno
- Correlación
- …

DISTANCIA: Similitud y Disimilitud



Veremos casos donde la similitud esta asociada a una cercanía geométrica pero otros casos, se necesitará otro tipo de distancia que mida mas que la distancia geométrica, que mida grado de conectividad entre muestras o su distribución.

¿Cómo evaluamos un modelo de Aprendizaje No Supervisado?

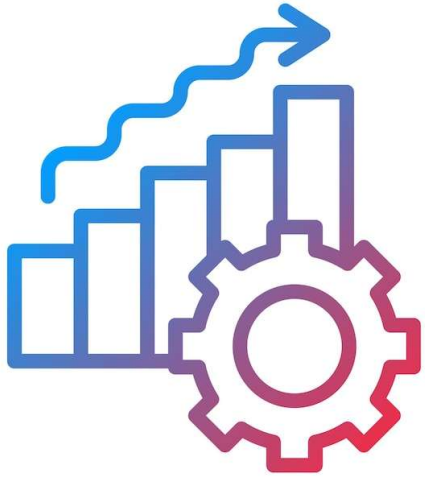


¿Cómo evaluamos un modelo de Aprendizaje No Supervisado?

Hemos visto que el aprendizaje no supervisado es un desafío porque no existen un feedback, una señal evaluativa que nos diga si lo hacemos bien o no.

Por otro lado, le uso de métricas depende de la tipología de la tarea: clustering, reducción de dimensionalidad, reglas de asociación, …

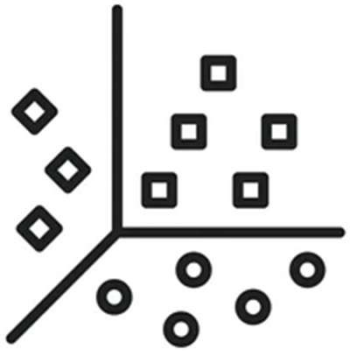
Esto lleva a que la evaluación de un modelo depende mucho del problema, es decir, depende del modelo usado.

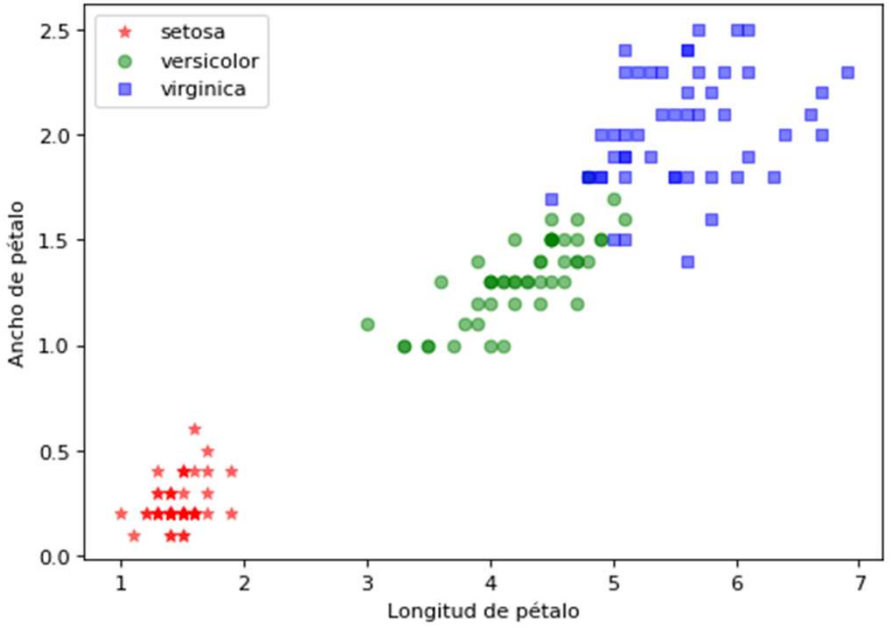


Tipos de modelos que vamos a ver en la asignatura

Universidad Internacional de Valencia

- **Clustering**

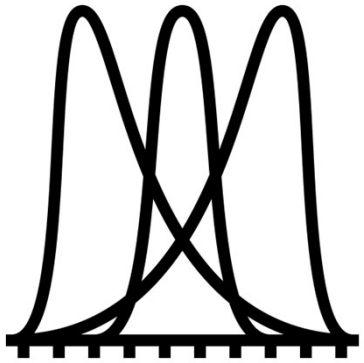




- ❑ **Silhouette Score:** Evalúa la cohesión dentro de cada cluster y separación entre clusters
- ❑ **Coeficiente de Dunn:** Relación entre la distancia mínima entre clusters y el diámetro del cluster más grande.
- ❑ **Indice Davies-Bouldin:** Relación u dispersión interna con la separación respecto a los demás clusters.

Tipos de modelos que vamos a ver en la asignatura

- **Probabilísticos**



- **Log-Likelihood:** mide como de bien el modelo explica los datos observados.
- **AIC:** compara modelos probabilísticos teniendo en cuenta tanto su calidad de ajuste como su complejidad
- **BIC:** compara modelos probabilísticos teniendo en cuenta tanto su calidad de ajuste como su complejidad (se diferencia del AIC en como realiza la penalización)

Tipos de modelos que vamos a ver en la asignatura

viu Universidad Internacional de Valencia

- **Semi - Supervisados**

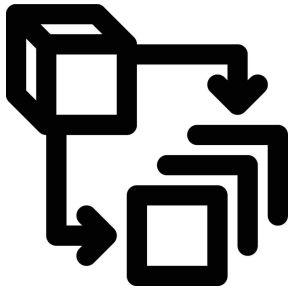


❑ **Matriz de confusión** y todas las métricas surgidas de esta.

		Ground truth: +	Ground truth: -	
Predicted	+	True positive (TP)	False positive (FP)	Precision = TP / (TP + FP)
Predicted	-	False negative (FN)	True negative (TN)	
		Recall = TP / (TP + FN)		Accuracy = (TP + TN) / (TP + FP + TN + FN)

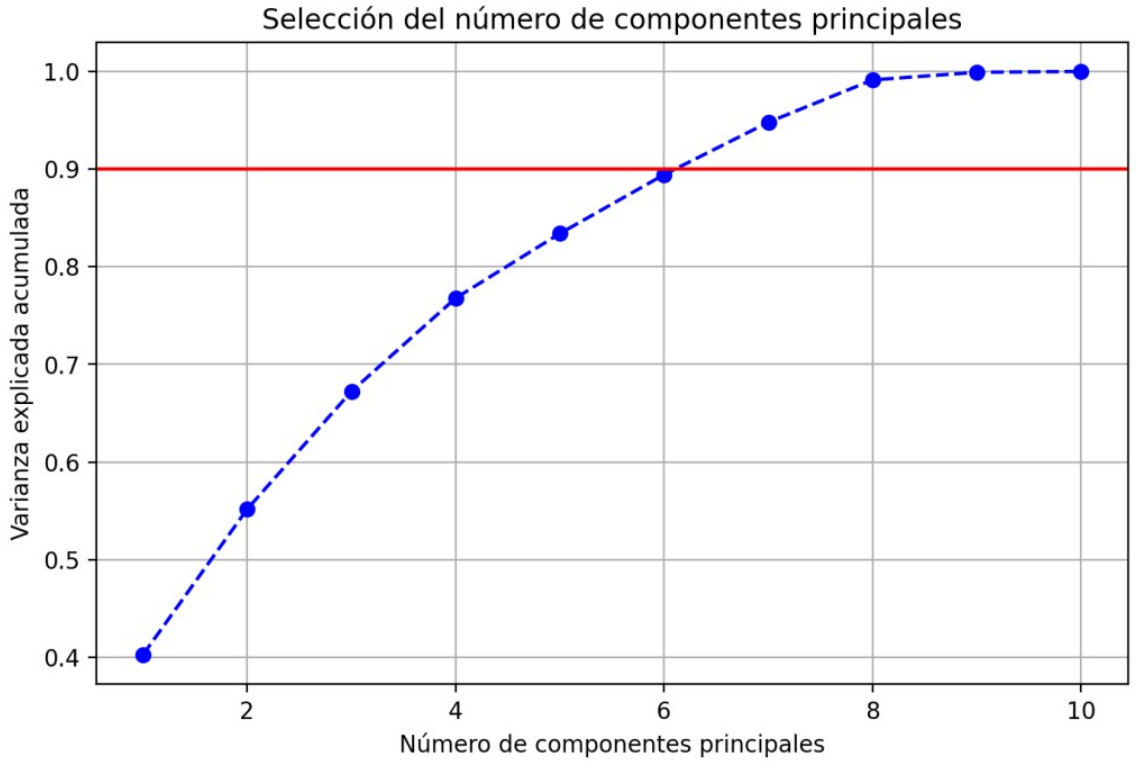
Tipos de modelos que vamos a ver en la asignatura

- **Reducción de dimensionalidad**



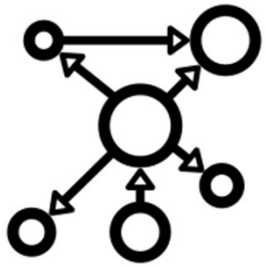
- **Varianza explicada:** métrica utilizada principalmente en técnicas de **reducción de** dimensionalidad, como PCA, para medir cuánta información de los datos originales conserva cada componente.

- **Error de reconstrucción:** métrica que mide cuánto se pierde al representar los datos en un espacio de menor dimensión y después reconstruirlos de nuevo en el espacio original.



Tipos de modelos que vamos a ver en la asignatura

- **Análisis de grafos y transacciones**

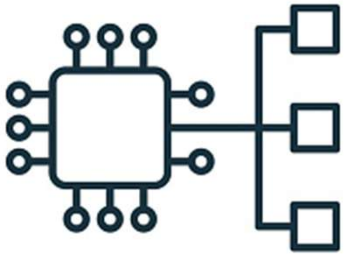


- ❑ **Modularity y Conductance:** son dos métricas utilizadas en análisis de grafos para evaluar la calidad de una división de la red en comunidades.
- ❑ **Support**: mide la frecuencia relativa de un evento con relación al número total de eventos.
- ❑ **Confidence**: mide la probabilidad condicional de que se dé un evento cuando otros se dan.
- ❑ **Lift**: mide la correlación real entre eventos.

Tipos de modelos que vamos a ver en la asignatura

Universidad Internacional de Valencia

- **Deep clustering**



- ❑ **Reconstrucción Loss o pérdida de reconstrucción**: métrica muy utilizada en Deep Clustering cuando el modelo incorpora un autoencoder.

- ❑ **Contrastive Loss** o **Representation Loss:** métrica usa en autoencoders para aprender en el espacio latente que las muestras similares queden próximas y las diferentes queden separadas.

- ❑ **FID:** métrica usada en modelos generativos compara las características de las imágenes reales con las generadas

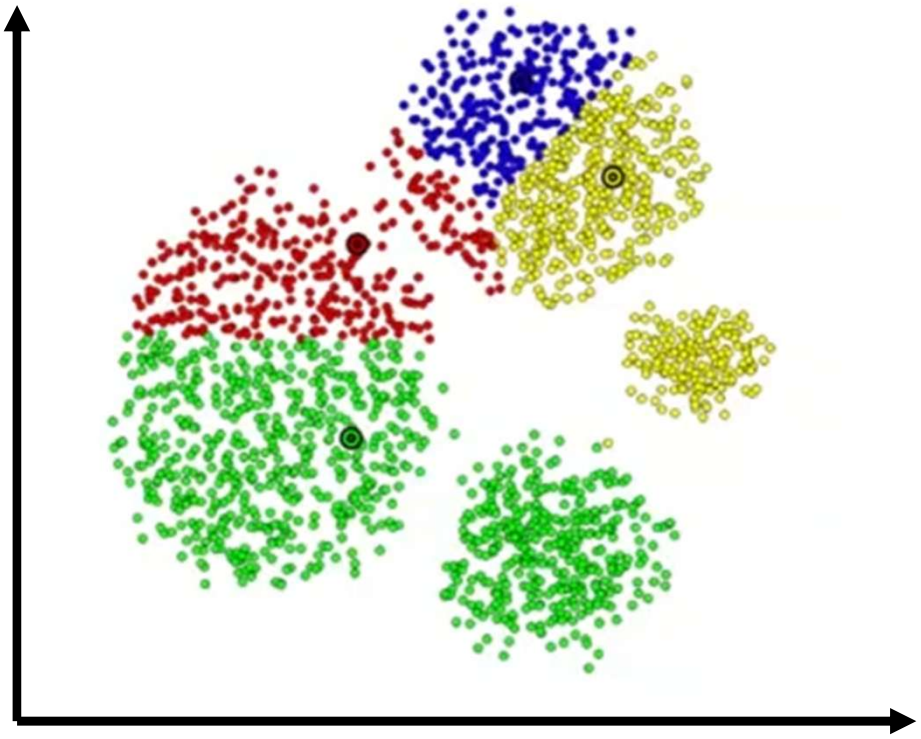
IMPORTANTE!!!
En Deep clustering también pueden usarse algunas de las métricas usadas arriba como son **Silhouette Score.**

Evaluación externa

Finalmente, debido a que no hay etiquetas siempre debemos hacer una evaluación externa y verifica, de algún modo, que el modelo lo esta captando las estructuras subyacentes de los datos.

Ejemplo Clustering

Que el agrupamiento (clustering) sea correcto.



Evaluación externa

Finalmente, debido a que no hay etiquetas siempre debemos hacer una evaluación externa y verifica, de algún modo, que el modelo lo esta captando las estructuras subyacentes de los datos.

Ejemplo Segmentación

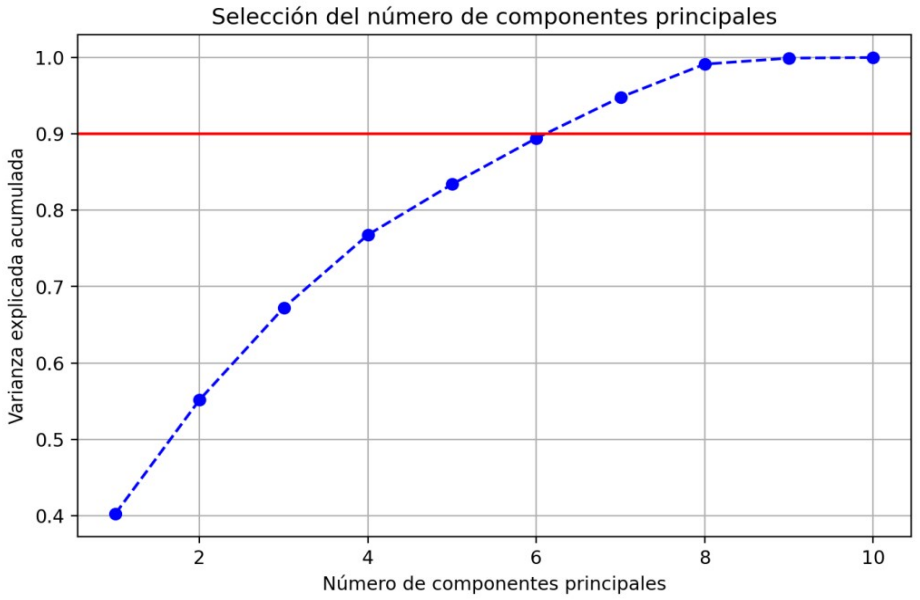
Que la segmentación tenga sentido.

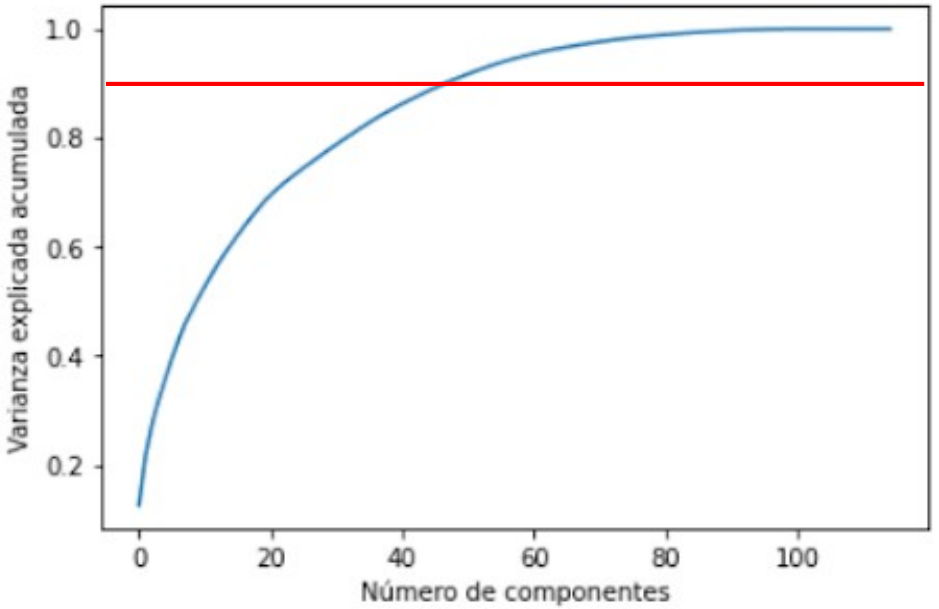


Evaluación externa

Ejemplo PCA

Que la reducción de dimensionalidad valga la pena.





Diferencia entre parámetros e hiperparámetros

PARÁMETRO

Coeficiente cuyo valor se aprende automáticamente durante el entrenamiento a partir de los datos. Por ejemplo, los pesos en las redes neuronales, la posición del centroide, etc …

HIPERPARÁMETRO

Coeficiente cuyo valor se define antes del entrenamiento y controla cómo aprende o se estructura el modelo. Por ejemplo, numero de clusters, métrica de distancia o numero de componentes principales.