Aprendizaje No Supervisado



Universidad Internacional de Valencia

T2.1 – Clustering basado en particiones

José María Escalante Fernández

Curso 2026-2027 (Ed Abril - Grupo B)

Máster Univ. en Inteligencia Artificial

De:
Planeta Formación y Universidades

Datos y Distancia

Universidad Internacional de Valencia

N características

M instancias o muestras

	X_1	X_2	X3	…	X_n
I_1	X_{11}	X_{12}	X_{13}	…	X_{1n}
I_2	X_{21}	X_{22}	X_{23}	…	X_{2n}
I_3	X_{31}	X_{32}	X_{23}	…	X_{3n}
…	…	…	…	…	…
I_M	X_{M1}	X_{M2}	X_{M3}	…	X_{Mn}

Vector representación de la muestra o instancia I_3

No son etiquetas, solo identificas la instancia

Basandonos en el concepto de distancia buscamos similitudes o disimilitudes en los datos, según convenga al modelo usado, para buscar relaciones entre datos y estructuras.

Aprendizaje No Supervisado: Técnicas y Modelos

Universidad Internacional de Valencia

Aprendiza No Supervisado

- Clustering
  - Basado en particiones
  - Jerárquico
  - Espectral
  - Basado en densidades
  - Probabilístico
- Semi-supervisado
- Reducción de dimensionalidad (Análisis de componentes)
- Grafos y transacciones (secuencias)
- Deep clustering

Modelos basados en particiones

Este tipo de modelos son probablemente los algoritmos más conocidos. La idea es dividir directamente los datos en un número determinado de grupos, buscando la mejor partición de los datos.

$$\mathbf{I} = \{I_1, I_2, I_3, \ldots, I_M\} \rightarrow \begin{cases} C_1 = \{I_1, I_{56}, \ldots, I_{853}\} \\ C_2 = \{I_4, I_{52}, \ldots, I_{326}\} \\ C_n = \{I_{10}, I_{102}, \ldots, I_{588}\} \end{cases}$$

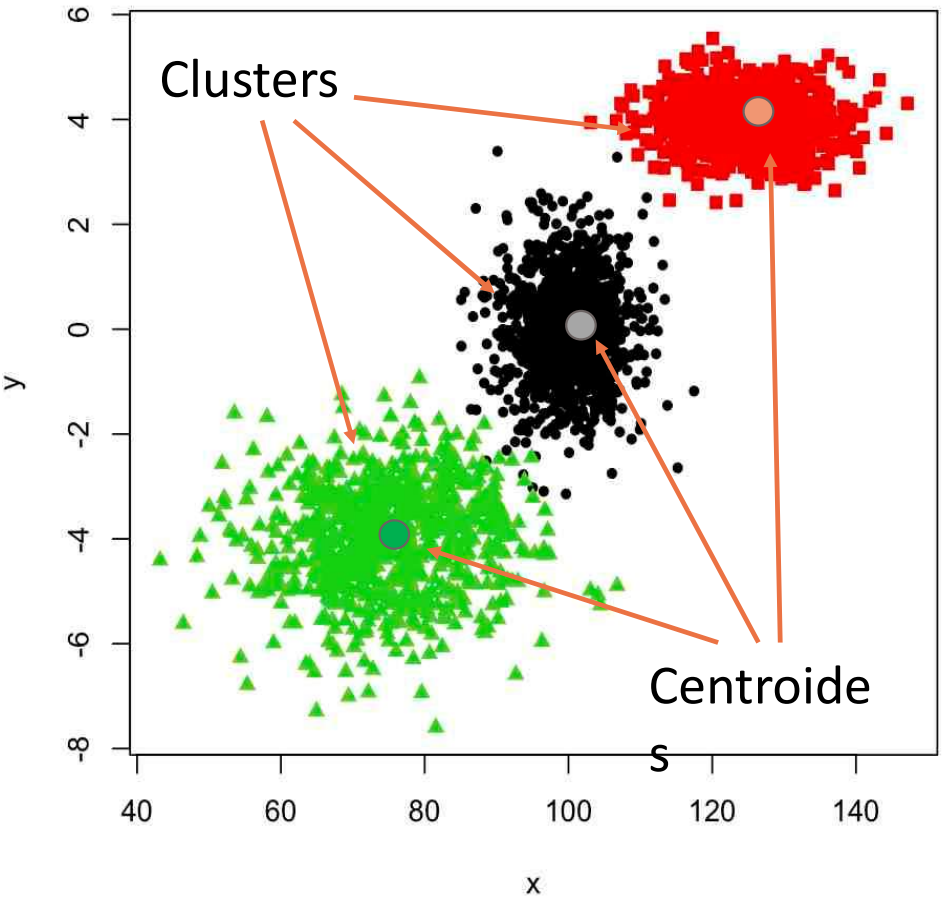
$$\mathbf{I} = C_1 \cup C_2 \ldots \cup C_n \qquad \mathbf{I} = C_i \cap C_j = \phi,\ i \neq j\ \forall i,j$$

¿Pero como se agrupan esos datos?

El objetivo es:

- minimizar la varianza (dispersión) **INTRA-clusters**
- maximizar la varianza (dispersión) **INTER-cluster**.

En otras palabras, se busca que las muestras dentro de un cluster se parezcan mucho entre si y que las muestras de diferentes clusters se diferencien mucho entre si.



Un **centroide** es el punto que representa el centro de un cluster, calculado normalmente como la media de las coordenadas de todos los datos que pertenecen a ese grupo.

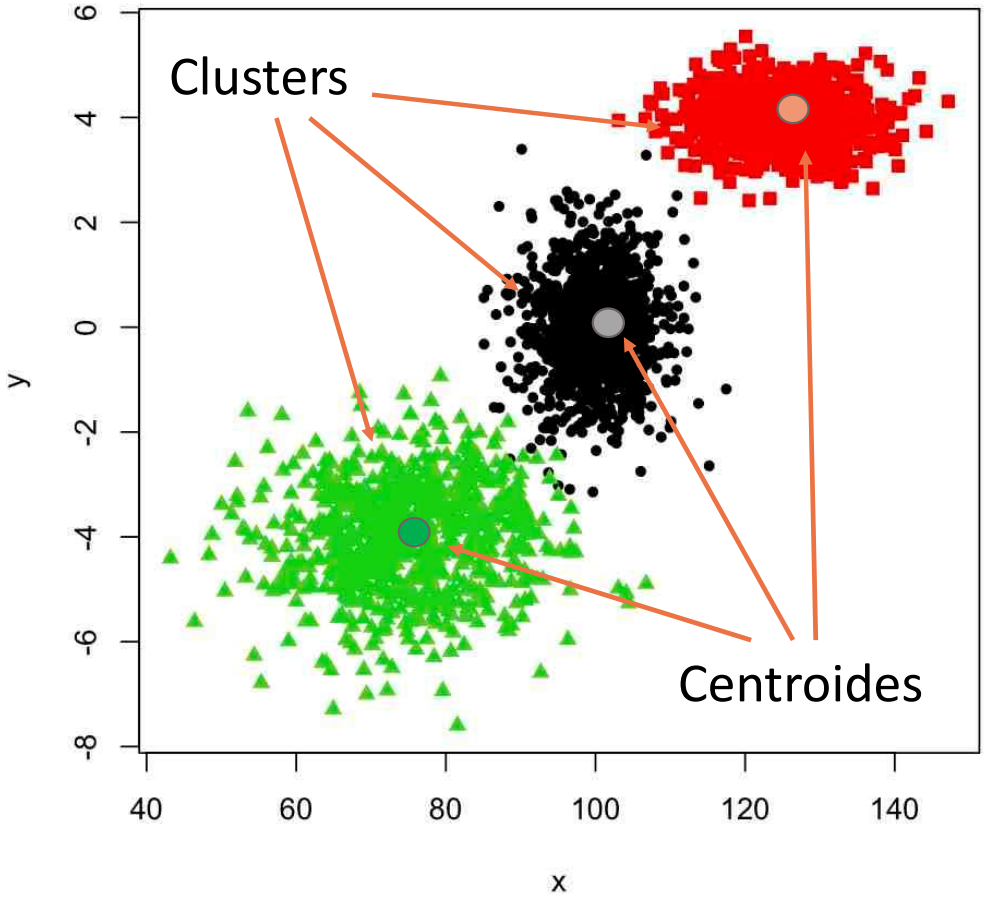
¿Pero como se agrupan esos datos?

Dispersión intraclúster

$$I(C) = \frac{1}{2}\sum_{k=1}^{K}\sum_{i:C(x_i)=k}\sum_{i':C(x_{i'})=k} d(x_i, x_{i'})$$

Dispersión interclúster

$$O(C) = \frac{1}{2}\sum_{k=1}^{K}\sum_{i:C(x_i)=k}\sum_{i':C(x_{i'})\neq k} d(x_i, x_{i'})$$



El objetivo es *min[I(C)]* y *max[O(C)]* a la vez. Esto se puede hacer de muchas formas, por ejemplo, hay casos donde se le da mas peso a *min[I(C)]* que a *max[O(C)],* o viceversa.

Algoritmo K-means

K-means es el principal algoritmo dentro de los algoritmos basados en particiones. Su funcionamiento es muy sencillo e intuitivo y rápido.

1. **Inicialización de los centroides -** El proceso comienza con la selección de K puntos como centroides iniciales (completamente aleatorios).

2. **Asignación -** Para cada punto del conjunto de datos se calcula la distancia entre este punto y los centroides, asignándole el centroide mas cercano.

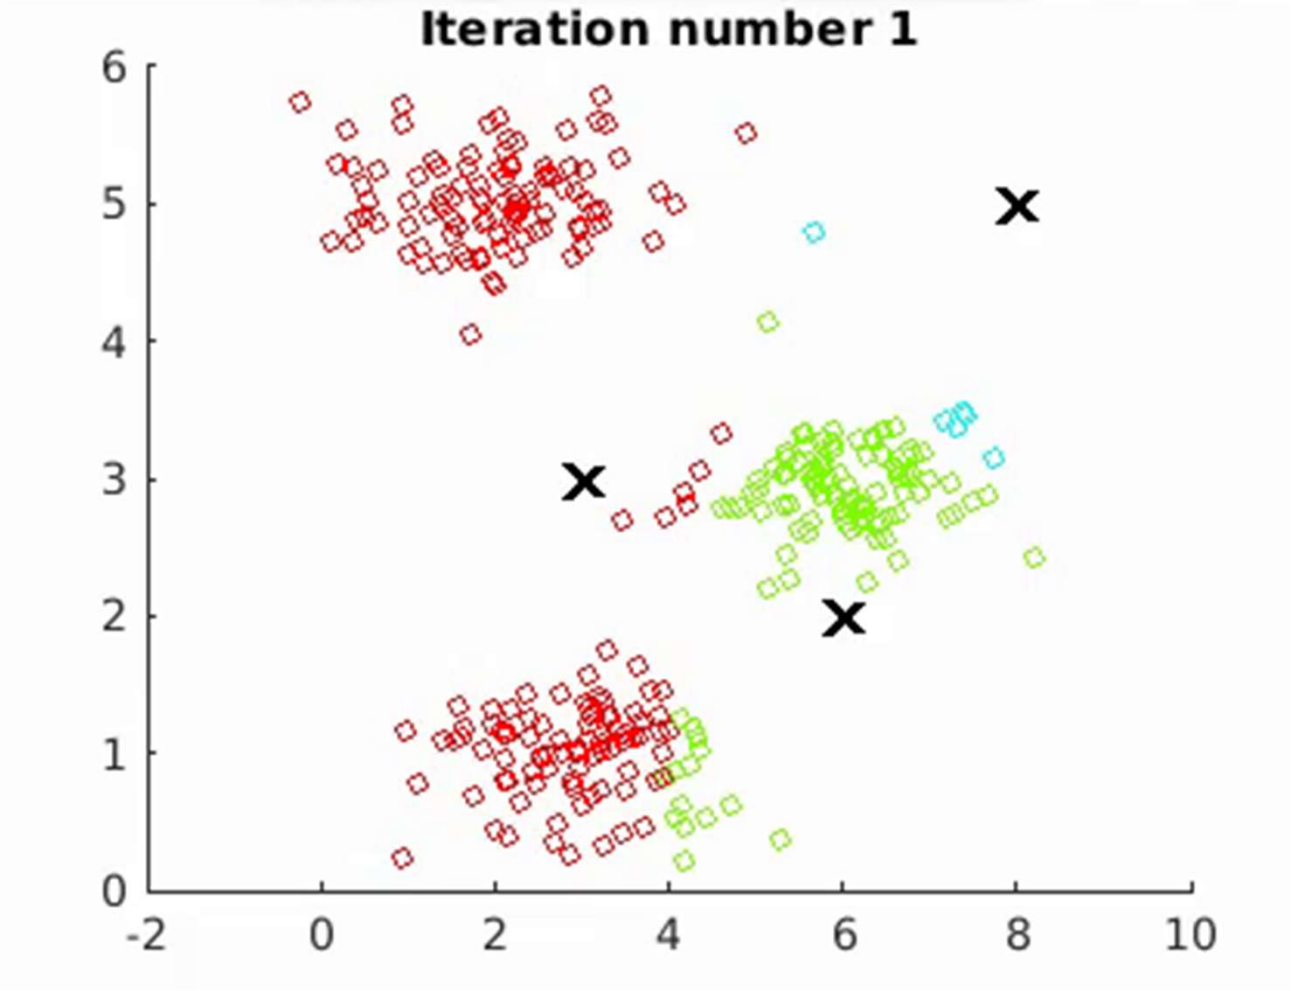
3. **Actualización -** Se recalcula la posición de cada centroide del cada uno de los grupos realizados.

4. **Reasignación –** Se vuelve a calcular para cada punto la distancia a los nuevos centroides, asignándole el centroide mas cercano.

5. **Convergencia –** El proceso de reasignación se repite hasta que la posición de los centroides no cambia, llegando a este punto a la formación final de los clusters.

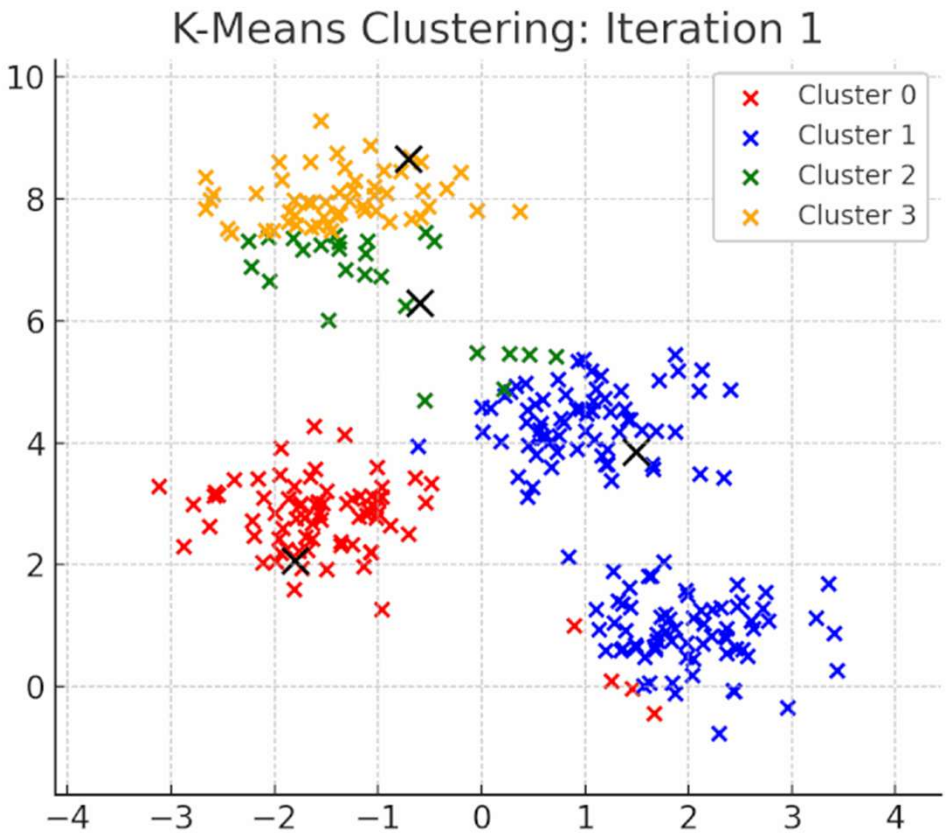
K-means paso a paso

1. Inicialización de los centroides
2. Asignación
3. Actualización
4. Reasignación
5. Convergencia



K-means paso a paso

1. **Inicialización de los centroides**
2. **Asignación**
3. **Actualización**
4. **Reasignación**
5. **Convergencia**



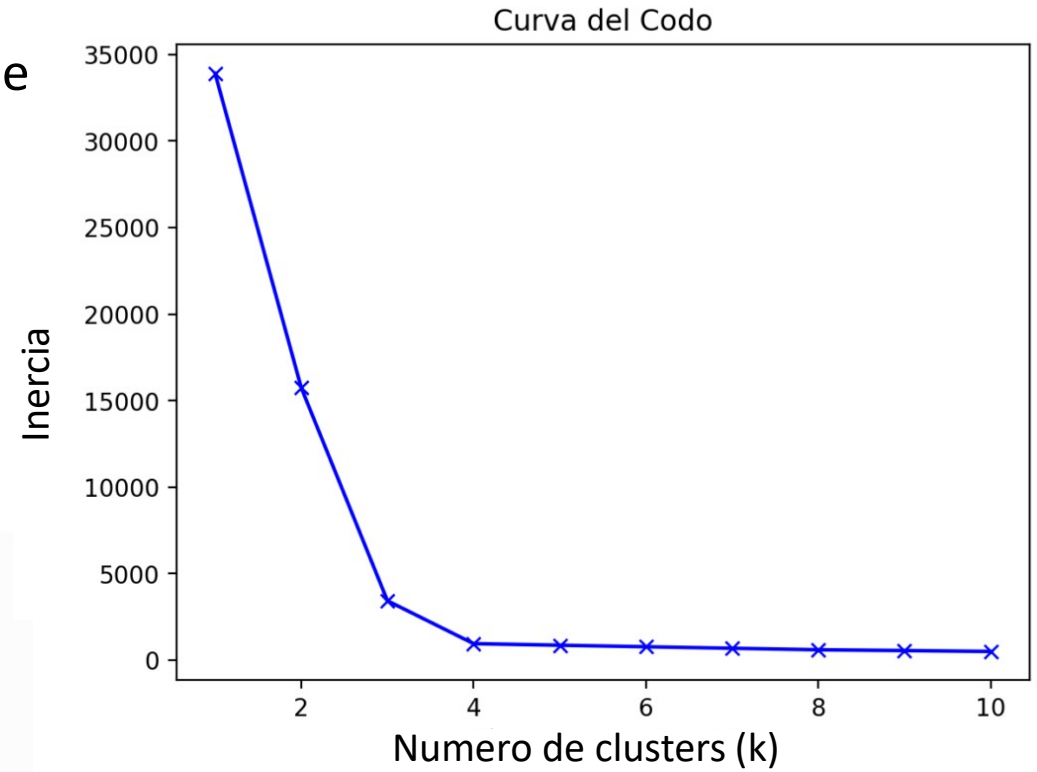
Pero ¿Cómo se elije el numero optimo de clusters?

El método del codo

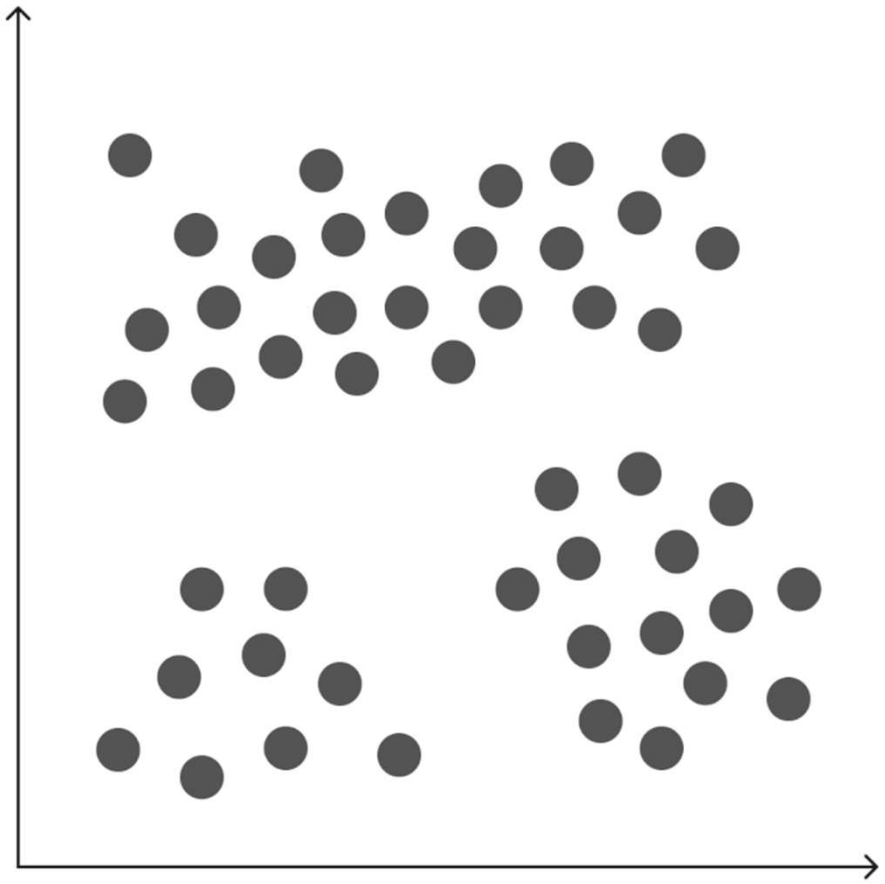
Inercia es la suma de las distancias cuadráticas de cada punto al centroide de su cluster.

$$I = \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

- K: número de clusters.
- C_k: conjunto de puntos del cluster k.
- x_i: cada observación.
- μ_k: centroide del cluster k.
- $\|x_i - \mu_k\|^2$: distancia euclídea al cuadrado entre el punto y su centroide.



Pero ¿Cómo se elije el numero optimo de clusters?



Pero ¿Cómo se elije el numero optimo de clusters?

Universidad Internacional de Valencia

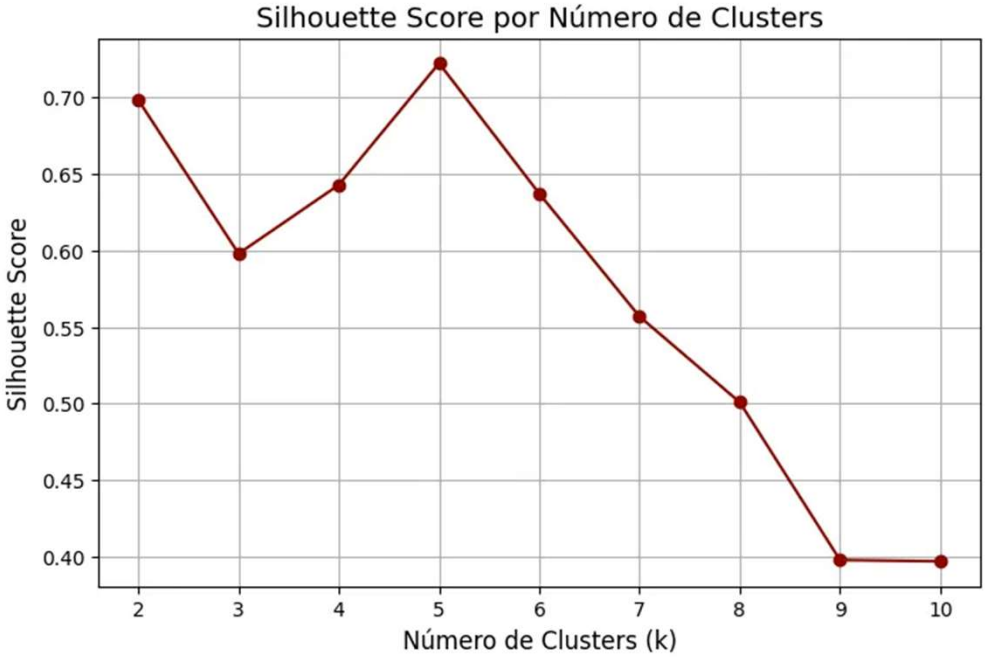
Índice de Silueta

Indice de silueta para un punto viene definido como:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Indice de silueta total es:

$$S = \frac{1}{N} \sum_{i=1}^{N} s(i) \qquad -1 \leq S \leq 1$$



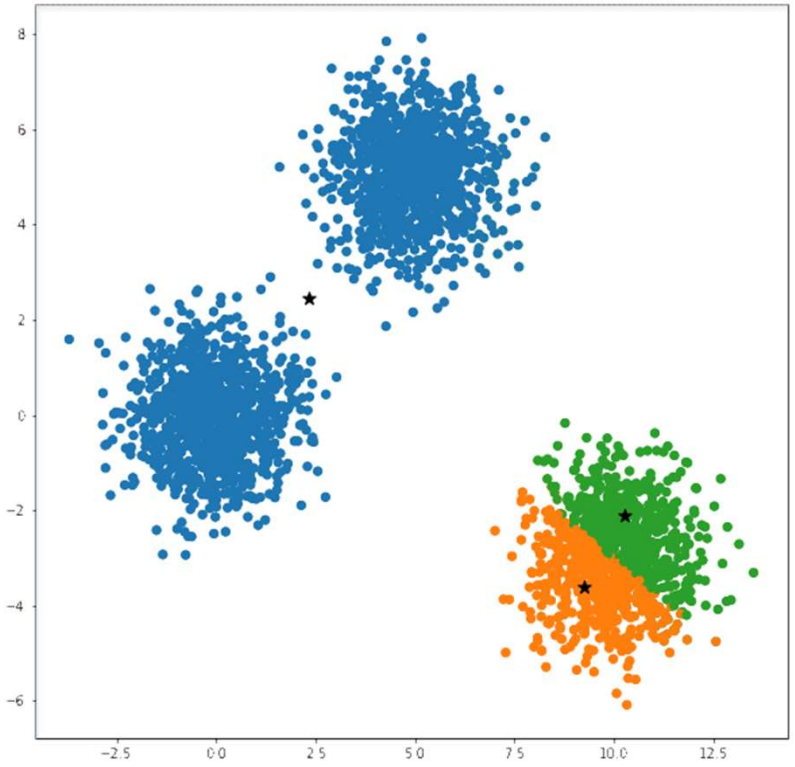
- $a(i)$: distancia media del punto i al resto de puntos de su mismo cluster.
- $b(i)$: menor distancia media del punto i a los puntos de cualquier otro cluster.

Principal problema del algoritmo K-means

Ventajas	Inconvenientes
Es simple y fácil de implementar	Hay que indicar previamente el número de clusters K (los métodos pueden fallar)
Es rápido y eficiente para conjuntos de datos grandes	Es sensible a la inicialización de los centroides
Escala bien con muchas observaciones	Puede converger a mínimos locales
Es fácil de interpretar	Es sensible a outliers y valores extremos
Funciona muy bien con clusters compactos y aproximadamente esféricos	Funciona mal con clusters de formas complejas o no convexas
Tiene bajo coste computacional comparado con otros métodos	Tiene problemas cuando los clusters tienen tamaños o densidades muy diferentes
Permite usar métricas como WCSS, Silhouette o Davies-Bouldin para evaluar resultados	Requiere que las variables estén correctamente escaladas

Principal problema del algoritmo K-means

- Sensible a la inicialización de los centroides
- Puede converger a mínimos locales



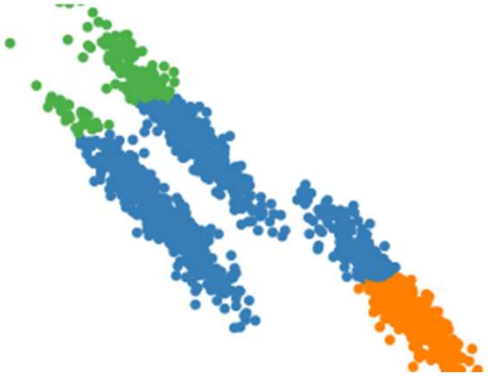
Principal problema del algoritmo K-means

- Funciona mal con clusters de formas complejas o no convexas
- Tiene problemas cuando los clusters tienen tamaños o densidades muy diferentes



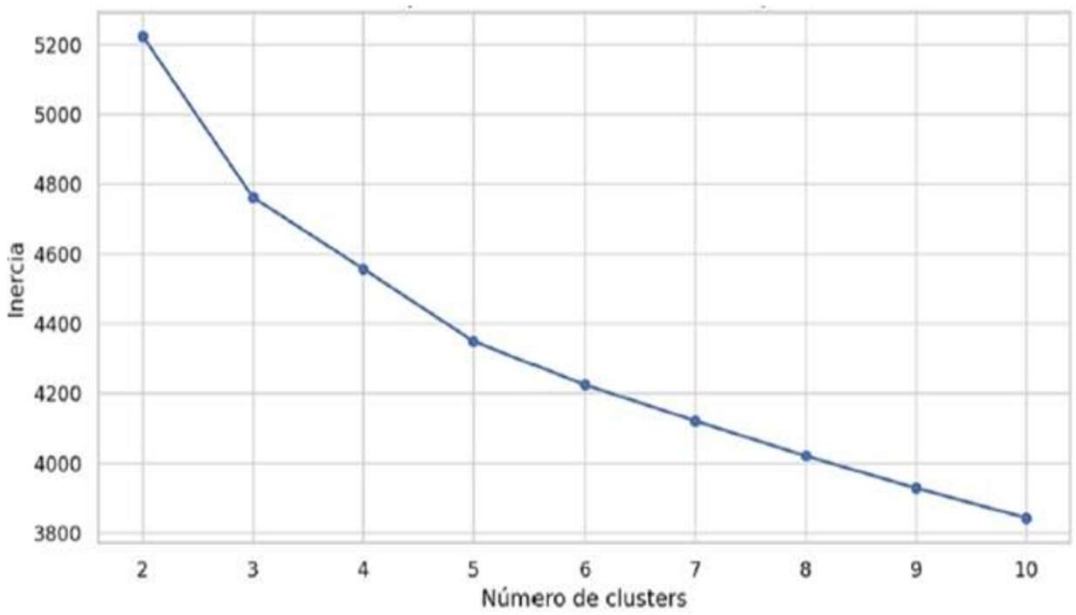


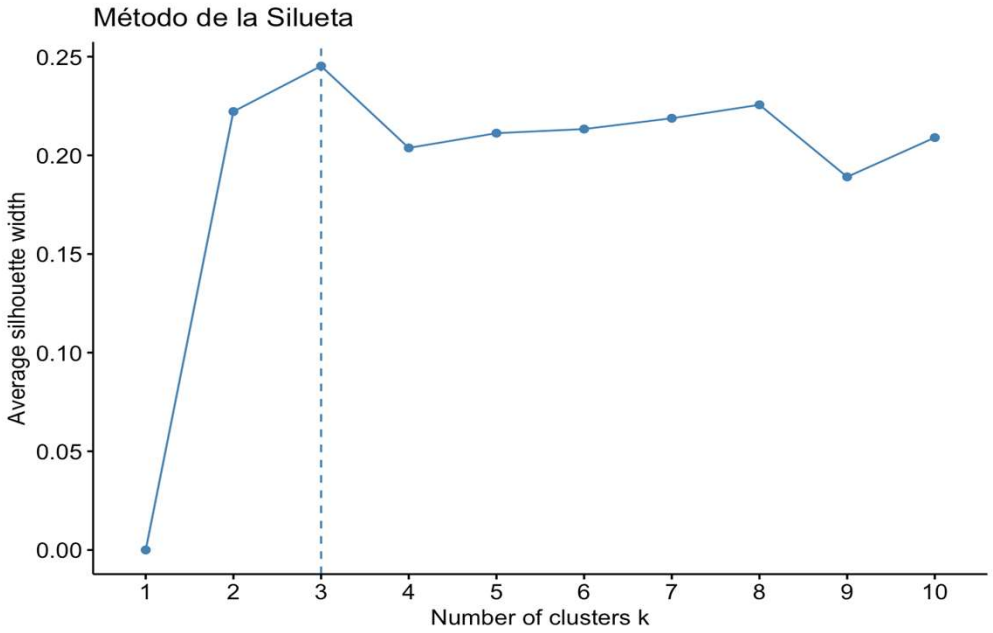




Principal problema del algoritmo K-means

- Hay que indicar previamente el número de clusters K (los métodos pueden fallar)





MEJORAS del algoritmo K-means

El principal problema de **K-Means** es que la elección inicial de los centroides es completamente aleatoria, lo que puede hacer que el algoritmo converja a un óptimo local pobre o lento, además de ser muy sensible al ruido y a los valores atípicos (*outliers*), ya que calcula los centros como medias aritméticas.

K-means mejorado:

- **K-means++**
- **K-medoids**

K-means++ y K-mdeoids

Universidad Internacional de Valencia

- **K-means++**

  No es otro algoritmo, simplemente una mejora estratégica de inicialización.

  Para separar los centroides iniciales, el primer centroide se elige al azar, pero los siguientes se seleccionan con una probabilidad proporcional a su distancia al cuadrado del centroide más cercano ya existente. **Esto fuerza a que los nuevos centroides estén lo más lejos posible de los ya elegidos.**

- **K-means++ e**l

  No es otro algoritmo, simplemente el centro del cluster no es una media ni una mediana artificial, es un punto asociado a un dato real del cluster. Y se le exige a este punto que su distancia total al resto de los elementos del cluster sea mínima.

Quitando esas diferencias, los siguientes pasos de ambos algortimos son similares al K-means.